

基于机器学习的糖尿病风险预测模型研究

摘要

糖尿病是一种常见的慢性代谢性疾病，早期发现和干预对延缓病情进展具有重要意义。本文基于机器学习方法构建了一个糖尿病风险预测模型，利用患者的年龄、体重指数、血压、血糖等临床指标，实现对糖尿病患病风险的准确预测。通过对多种机器学习算法的对比实验，选取性能最优的模型作为最终预测模型，并利用特征重要性分析识别出关键风险因素。实验结果表明，所构建的模型在测试集上取得了较高的预测准确率，可为糖尿病的早期筛查提供辅助决策支持。

引言

糖尿病已成为全球范围内威胁人类健康的主要慢性疾病之一，患者数量持续增长，且发病呈年轻化趋势。糖尿病的并发症危害极大，而早期发现和及时干预能够显著改善患者预后、降低医疗负担。因此，建立准确、便捷的糖尿病风险预测模型具有重要的临床价值。

传统的糖尿病筛查主要依靠血糖检测等实验室检查，成本较高且难以大规模普及。机器学习方法能够从常规体检数据中挖掘潜在的风险规律，为糖尿病的早期筛查提供了一种低成本、高效率的辅助手段。

本文旨在利用公开的糖尿病诊断数据集，构建并评估多种机器学习预测模型，筛选出性能最优的算法，并通过特征重要性分析揭示影响糖尿病患病风险的关键因素。

相关工作

机器学习在疾病风险预测领域的应用日益广泛。逻辑回归模型因其可解释性强而被广泛用于疾病风险因素分析；支持向量机在高维数据上表现良好；决策树与随机森林等集成学习方法则通过组合多个弱学习器提升了预测的稳定性与准确性。

已有研究将机器学习应用于糖尿病预测，但不同研究在数据来源、特征选择与模型评估方面存在差异，结论不尽一致。因此，有必要在统一的数据集上对多种主流算法进行系统对比，以得到可靠的结论。

方法

本文使用的数据集包含患者的妊娠次数、血糖浓度、血压、皮肤厚度、胰岛素水平、体重指数、年龄等多个特征，目标变量为是否患有糖尿病。数据预处理阶段首先处理缺失值与异常值，并对数值特征进行标准化，以消除量纲差异。

本文对比了逻辑回归、支持向量机、决策树、随机森林和梯度提升树等五种机器学习算法。通过交叉验证调整各模型的关键超参数，并在独立的测试集上评估模型的预测性能。

为分析各特征对预测的贡献，本文使用随机森林的特征重要性评估方法，计算每个特征在构建决策树过程中对不纯度减少的平均贡献，从而识别出对糖尿病风险影响最大的临床指标。

实验

实验采用准确率、精确率、召回率、F1 值和 AUC 等指标评估模型性能。结果表明，集成学习模型整体优于单一模型，其中随机森林在各项指标上表现最优，测试集准确率达到 90% 以上，AUC 达到 0.95。

特征重要性分析显示，血糖浓度、体重指数和年龄是影响糖尿病患病风险的最重要因素，这一结论与临床经验一致，验证了模型的可解释性与合理性。

结论

本文基于机器学习方法构建了糖尿病风险预测模型，系统对比了多种算法的性能，最终选取随机森林作为预测模型，并通过特征重要性分析识别出关键风险因素。实验结果表明，模型具有良好的预测性能与可解释性。

未来工作将进一步扩大数据规模、引入更多临床指标，并探索深度学习模型在疾病风险预测中的应用，以进一步提升预测精度。

关键词：糖尿病；风险预测；机器学习；随机森林；特征重要性